

Podstawy Sieci Neuronowych	
Kierunek: Informatyczne Systemy Automatyki	Termin Poniedziałek 17.05
Imię, nazwisko, numer albumu Bartłomiej Kuk 272497 Daria Siwiak 272510	Data 09.12.2024



Spis treści

Spis treści	1
Wstęp.....	1
Analiza problemu.....	1
Przygotowanie Programu	1
Analiza danych	2
Przygotowanie danych.....	2
Wybór architektury sieci.....	2
Trenowanie sieci	3
Analiza uzyskanych wyników	3

Wstęp

Sztuczna sieć neuronowa (SSN) to struktura zbudowana z pojedynczych, ułożonych w warstwy jednostek obliczeniowych nazywanych neuronami. Sygnały (dane) wejściowe są przesyłane kolejno przez wszystkie warstwy neuronów w sieci. Zadaniem neuronów jest wypracowanie rozwiązania na podstawie podanych sygnałów wejściowych. Taka budowa pozwala na równoległe przetwarzanie informacji oraz nadaje sieci zdolność samodzielnego uczenia się.

Analiza problemu

W naszym projekcie wybraliśmy problem klasyfikacji psów i kotów na podstawie obrazu. Naszym celem, w procesie rozwiązywania tego problemu, było osiągnięcie jak najwyższej dokładności klasyfikacji zadanych obrazów oraz uzyskanie przy tym optymalnej liczby warstw, neuronów i struktury naszej sieci.

Przygotowanie Programu

Program stworzony do realizacji projektu został napisany w języku programowania Python, z pomocą bibliotek:

- TensorFlow/Keras – główny framework użyty do budowy i trenowania sieci,
- Matplotlib, Seaborn – wizualizacja uzyskanych wyników (wykresy, macierze pomyłek),
- Sklearn – obliczanie metryk, takich jak macierze pomyłek i raport klasyfikacji,
- PIL – przetwarzanie obrazów,

Dzięki użyciu odpowiednich funkcji w programie, uzyskane wyniki trenowania zostały zapisane w formie graficznej do konkretnych folderów. Przy takim zabiegu porównanie oraz analiza uzyskanych danych była łatwiejsza oraz bardziej dokładna.

Analiza danych

Dane zostały podzielone na zbiory w proporcjach:

- Testowy: 10% - Dane testowe używane są tylko do sprawdzenia programu i nigdy nie trafiają do sieci.
- Treningowy: 89% - Danych treningowych powinno być najwięcej, aby podczas procesu nauczania sieci zaprezentować jak największą różnorodność zdjęć.
- Walidacyjny: 1% - Zestaw danych walidacyjnych służy do tego, aby jak najlepiej ocenić progres uczenia się sieci, dzięki prowadzeniu walidacji zawsze na tym samym zestawie danych.

Przygotowanie danych

Dane wykorzystane do uczenia sieci neuronowej to zdjęcia psów oraz kotów zapisane w formacie JPG, skalowane do rozmiaru 150x150px oraz – przy użyciu generatora – normalizowanie do skali [0,1] i przekształcanie tak, aby zwiększyć różnorodność danych wejściowych.

Wybór architektury sieci

Do naszego projektu wybraliśmy dwie różne architektury sieci neuronowych:

1. Fully Connected Network (FCN) - rodzaj sieci neuronowej, w której każdy neuron w jednej warstwie łączy się ze wszystkimi neuronami w następnej warstwie, co umożliwia jej naukę złożonych wzorców w danych. Ilość neuronów w kolejnych warstwach nie zmienia się.
2. Dimensional Reduction Network (DRN) - rodzaj sieci neuronowej, w której każdy neuron w jednej warstwie łączy się ze wszystkimi neuronami w następnej warstwie. Ilość neuronów w kolejnych warstwach zmniejsza się dwukrotnie.

Oraz nastawy odpowiednie dla obu architektur:

- Warstwy konwolucyjne: 4 warstwy z funkcją aktywacji ReLU (do uzupełnienia) i poolingiem (zmniejszanie obrazu dwukrotnie),
- Warstwy ukryte: 2 lub 3,
- Liczba neuronów w warstwie: 64, 128, 256, 512.
- Parametr uczenia dla każdej konfiguracji sieci jest taki sam i wynosi 0.001
- Warstwa wyjściowa: 1 neuron z funkcją Sigmoid (klasyfikacja binarna).

Trenowanie sieci

Trenowanie naszych sieci odbywało się pojedynczo - epoka po epoce. Do przerywania trenowania użyta została metoda earlyStopping (wcześniejszego zatrzymania), która zapobiega przetrenowaniu się sieci. Działa ona na zasadzie tolerancji 3 następnych epok – jeżeli w następnych trzech epokach dokładność działania dla danych walidacyjnych nie wzrośnie, to uczenie zostaje przerwane, a zapisana zostanie najlepsza konfiguracja. Bez użycia tej metody sieć trenowała by się przez 50 epok, co miało by wpływ na końcową dokładność działania naszej sieci.

Eksperymenty przeprowadzone zostały na podanych niżej parametrach:

- 2 typy sieci (FCN, DRN).
- 2 liczby warstw (2, 3).
- 4 liczby neuronów w warstwach (64, 128, 256, 512).

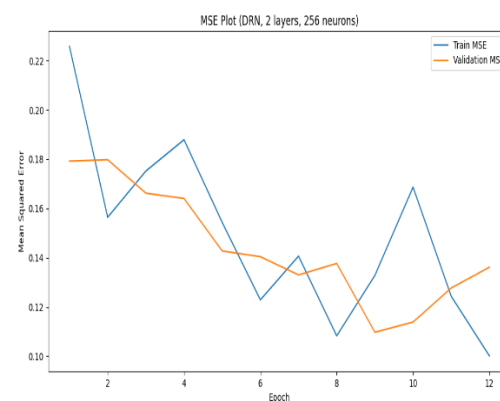
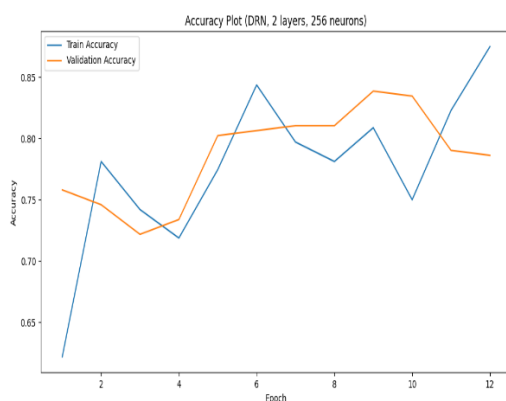
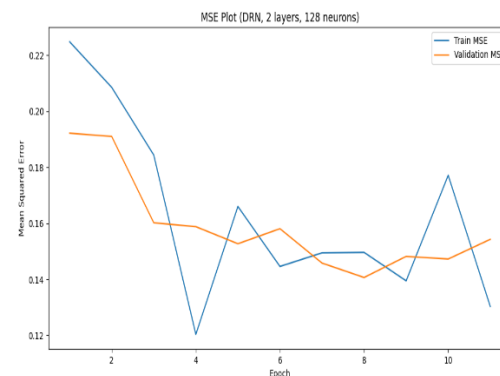



Analiza uzyskanych wyników

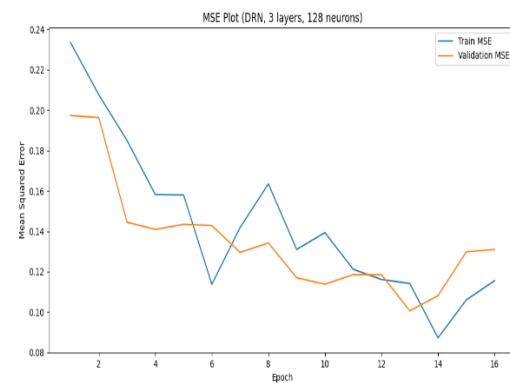





Przy początkowych założeniach projektowych ilość neuronów w pierwszej warstwie ukrytej miała być równa rozmiarowi obrazu, jednak w tym przypadku przeprowadzenie




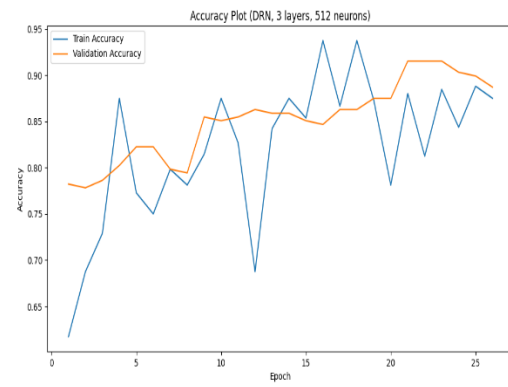


odpowiednich badań zajęło by zbyt długo. Po analizie możliwości sprzętowych oraz czasowych, uznaliśmy, że założenia podane w poprzednim punkcie będą odpowiednie do analizy wybranego problemu.



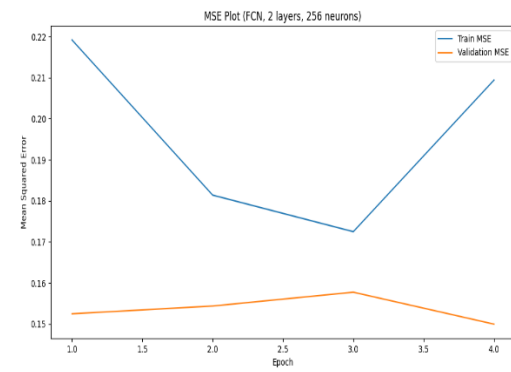
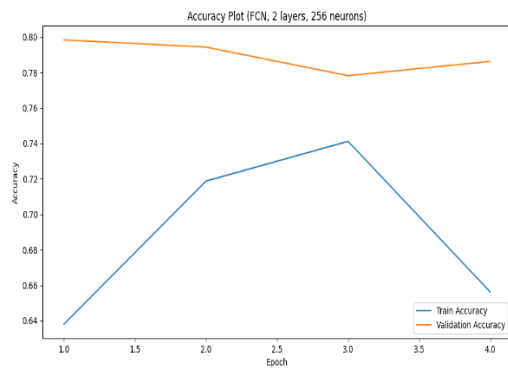

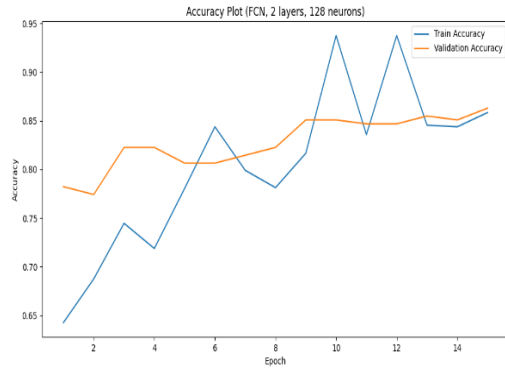
Wyniki trenowania sieci zostały zapisane w 3 różnych formach:

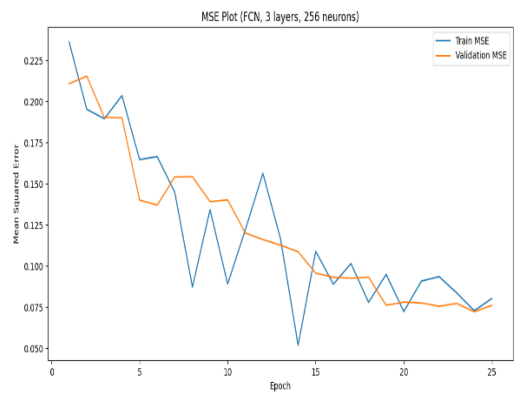
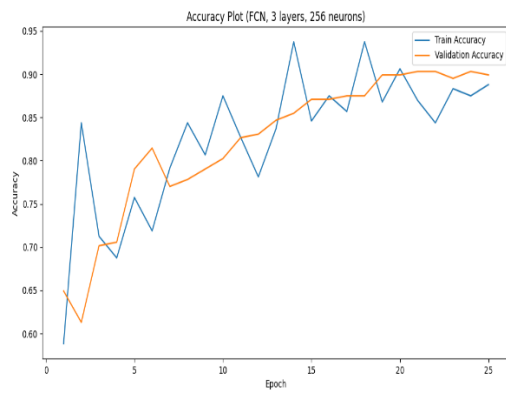

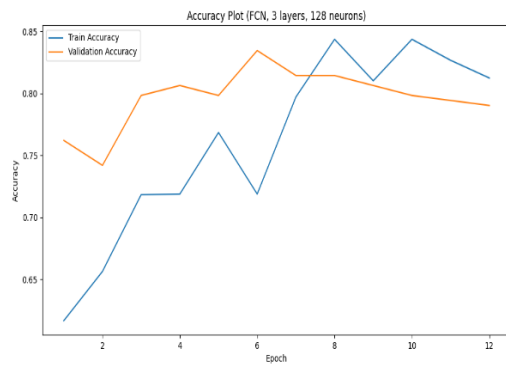


1. Wykresy dla różnych konfiguracji sieci:































2. Macierze trafień:





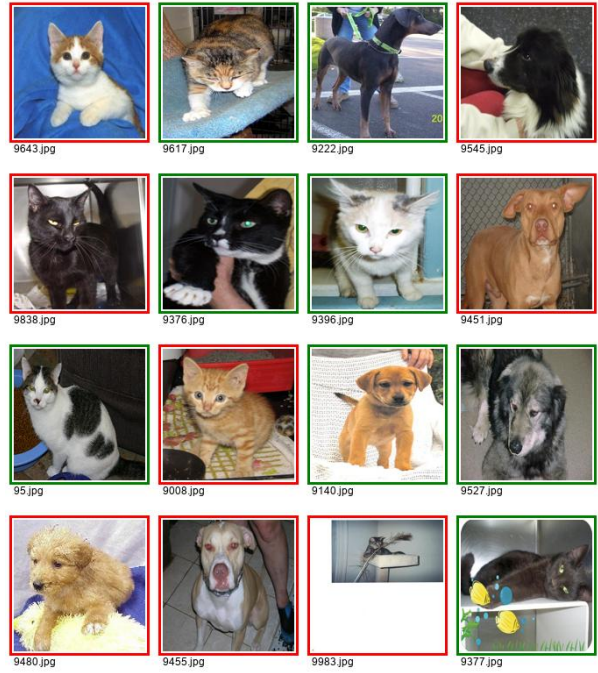


3. Przykładowe zdjęcia błędnie bądź poprawnie rozpoznane przez sieć:

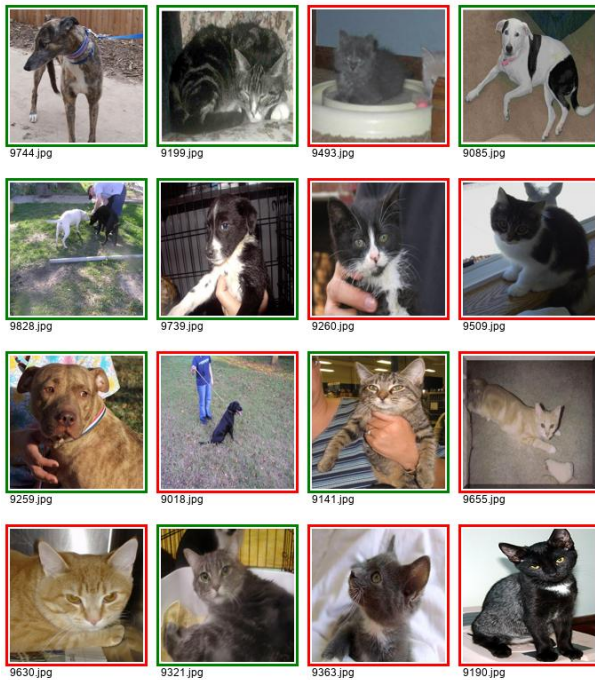
Network FCN prediction example for 2 layers, 256 neurons



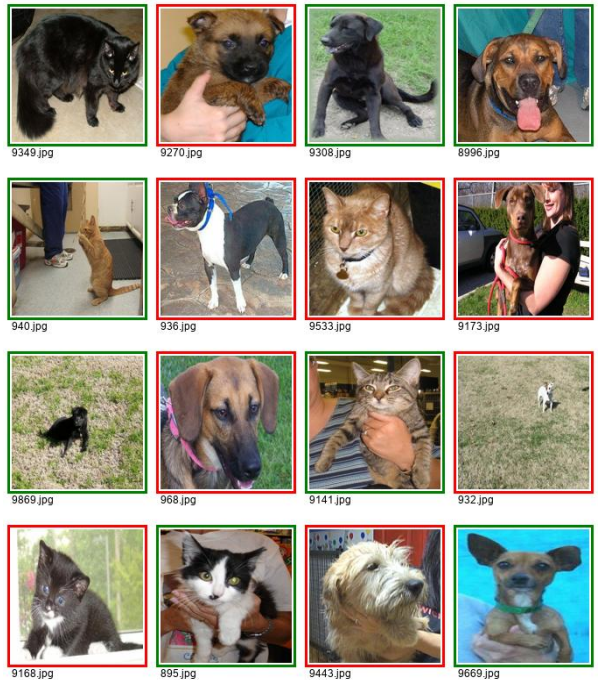
Network FCN prediction example for 2 layers, 512 neurons



Network FCN prediction example for 3 layers, 64 neurons



Network FCN prediction example for 3 layers, 128 neurons





Dla wszystkich szesnastu sieci neuronowych udało się uzyskać dokładność powyżej 1σ .

Po przeprowadzeniu badań najlepszy wynik dla zestawu testowego, czyli największą dokładność w okolicach 0.74, uzyskała sieć FCN z trzema warstwami ukrytymi i 256 neuronami na warstwę.

Ilość warstw konwolucyjnych ma wpływ na zaszumienie obrazu, co świadczy o tym że im więcej tych warstw użyjemy tym jesteśmy w stanie wydobyć więcej detali z obrazu.

Porównując wyniki dla sieci dwu oraz trzy warstwowych można stwierdzić, że dla tak złożonego problemu wymagane są przynajmniej 3 warstwy ukryte, aby możliwa była klasyfikacja jak największej ilości szczegółów.

Porównując ze sobą dwie użyte architektury – FCN i DRN – dla naszego problemu DRN nie sprawdza się, ponieważ ta architektura bazuje tylko i wyłącznie na porównywaniu różnych od siebie cech obrazu np. pies i żaba. Natomiast sieć FCN analizuje to porównanie dokładniej, rozróżniając nie tylko rodzaj badanego elementu ale również jego teksturę, co pozwala na uzyskanie lepszych wyników dla naszego problemu.